

Trabajo Práctico N°4

Métodos de Aprendizaje No Supervisado

Grupo 1

- Augusto Henestrosa
- Francisco Choi
- Nicolás de la Torre

Algoritmos a desarrollar

- Kohonen
- Oja
- Hopfield

Desarrollo

Python 3.8.0




Librerías utilizadas:

- Numpy
- Matplotlib
- Sklearn
- Pandas




Oja

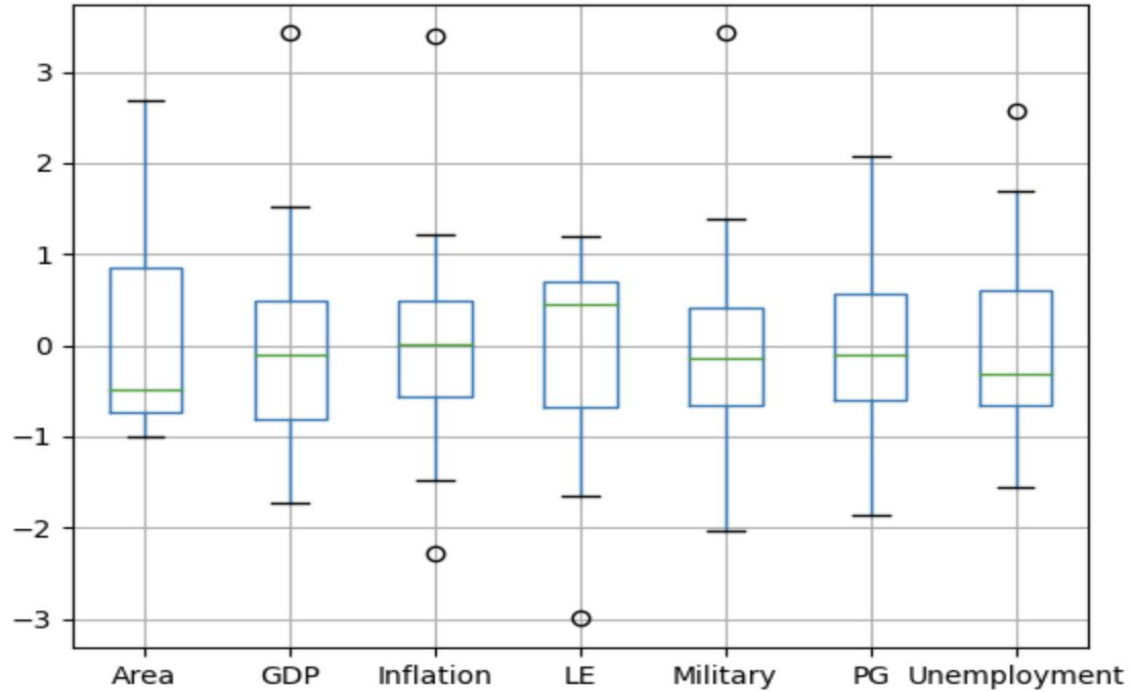
PCA



PCA




Distribución de las variables




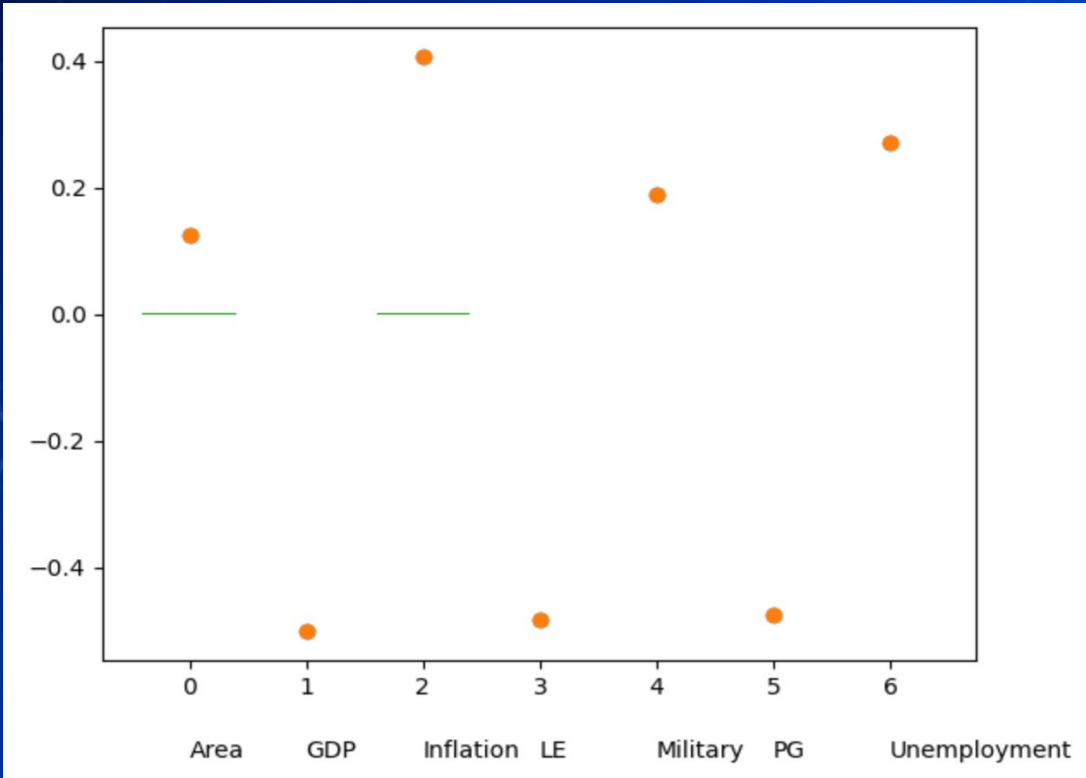
Diferencia entre PCA y Oja

Eta fijo




Diferencia entre PCA y Oja

Eta variable




Evolución de w

Inflación vs Desempleo



Evolución de w

PBI vs Esperanza de vida



● Oja
● Input

Kohonen

Kohonen - Testing

Entrenamos la red de neuronas variando los siguientes ítems:

- Inicialización del vector \rightarrow valores random o valores de la matriz de entrada
- Eta \rightarrow fijo o variable
- R \rightarrow fijo o variable
- Cálculo de la distancia \rightarrow distancia euclidiana o correlación

Relacionamos a cada país con su neurona más cercana y generamos:

- Mapa de calor
- Matriz de distancias (Matriz U)
- Indicador de país

Cálculo de Eta y R

Para eta variable utilizamos la fórmula:

$$\text{Eta} = 1/t$$

Para R variable utilizamos la fórmula:

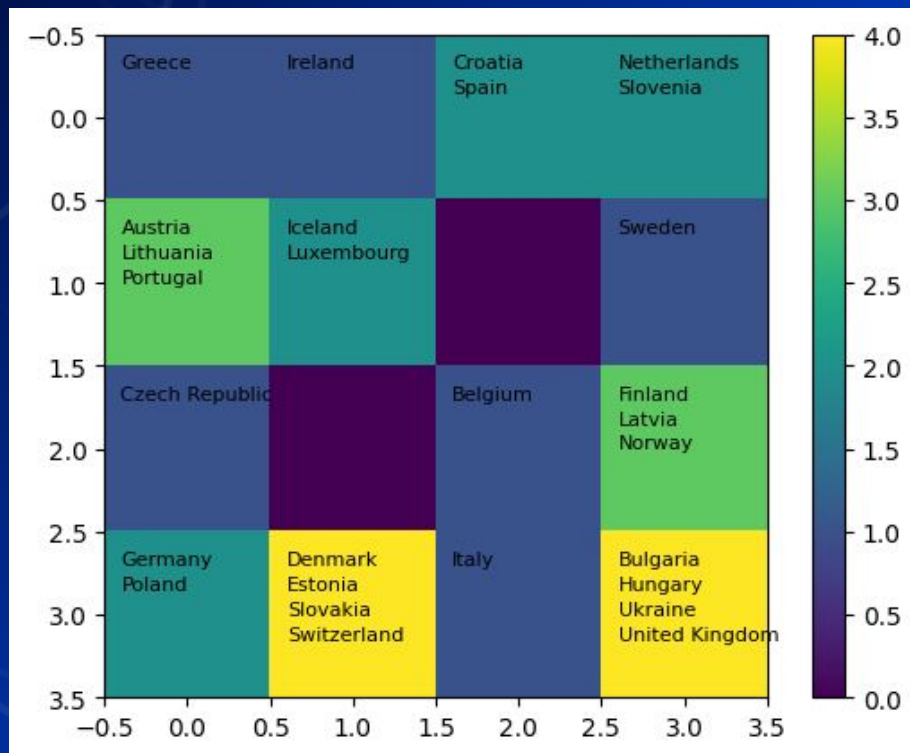
$$R = 1 + (R_0 - 1)e^{-0.002 * t} \quad R_0=2$$

Para R fijo: $R = \sqrt{2}$

Iteraciones: 1000

Todos los valores estandarizados

Kohonen - Resultados



R var


Eta fixed

Valores random


Distancia euclidea

Kohonen - Resultados


Matriz de distancias



Entrenamiento



Kohonen - Resultados



R var


Eta var

Valores iniciales


Distancia euclidea

Kohonen - Resultados


Matriz de distancias



Entrenamiento




Kohonen - Resultados




R var
Eta var
Inicialización random
Distancia euclídea

Kohonen - Resultados


Matriz de distancias



Entrenamiento



Kohonen - Resultados



R var


Eta var

Inicialización random


Correlación

Kohonen - Resultados


Matriz de distancias



Entrenamiento



Kohonen - Resultados



Hopfield

Hopfield - Testing

Buscamos cuatro patrones cuyo producto interno sea cercano a 1/-1

- Cambiamos las letras
 - J, A, T, O
 - J, E, C, A
 - F, A, N, J
 - A, M, K, Z
 - **A, K, M, I** → **Mejor producto interno**

Se selecciona una letra aleatoriamente y se le agrega ruido

- Ruido: [0.1; 0.4] incrementando de a 0.05


Hopfield - Testing

Patrones elegidos: A, K, M, I




Hopfield - Resultados

10% de probabilidad de mutación




Hopfield - Resultados

20% de probabilidad de mutación



Hopfield - Resultados

30% de probabilidad de mutación



Hopfield - Resultados

~~~~~ Initial Letter: ~~~~~

```

*           *
*  *       *  *
*       *   *  *
*           *  *
*           *  *
*           *  *

```




~~~~~ Results: 0.35 noise ~~~~~



~~~~~ Initial Letter: ~~~~~

- \*
- \*
- \*
- \*
- \*




~~~~~ Results: 0.35 noise ~~~~~

[illegible]


Hopfield - Resultados

Mutación vs Éxito



Hopfield - Resultados

Mutación vs Éxito




Patrones 'menos'
ortogonales: J E C A

Menos éxito!

Hopfield - Resultados

Energía


■ $P_m = 0.3$



Hopfield - Resultados

Energía

■ $P_m = 0.5$



Conclusiones

Conclusiones particulares

Oja

- La regla de Oja permite calcular los componentes principales de manera más rápida que PCA
- Utilizar esta variable permite calcular los componentes principales con mayor precisión

Kohonen

- Kohonen permite producir una representación discreta en forma de mapa
- Todas las configuraciones tuvieron resultados muy similares en cuanto a Error final (diferencia de 0.1)

Hopfield

- Con probabilidad de mutación mayor a 0.5 (mucho ruido) la red no tiene forma de distinguir patrones
- La red logra identificar patrones a pesar que las letras hayan sido drásticamente modificadas
- Es muy importante que los patrones sean ortogonales
- Con mucho ruido, la red puede converger a otro patrón o a un estado espúreo
- La energía es siempre descendente

Conclusiones generales

- Los métodos de aprendizaje no supervisado son muy útiles para clasificar y obtener información de un conjunto de datos sobre el que no tenemos información adicional
- Puede ser muy difícil determinar si están funcionando o no

A person is wearing a VR headset, looking upwards. The image is overlaid with a white network diagram consisting of interconnected nodes and lines. The background is a deep blue.

¡Gracias!